

LightVC — CIPT で話者天井を破る

出力側同一性の微分監督による 男性→ターゲット女性 ゼロショット音声変換

第 2 版 / 2026-07-08

要旨 — 基盤モデル m3b は自然な女性声を出せるが、出力の話者類似(SECS)が 0.5 で頭打ちになる「本人らしさの天井」を抱えていた。本稿はその原因を「男性 content の同一性漏れを、学習が出力側で一度も正していない」ことと特定し、CIPT (Cross-Identity Perceptual Training) — 生成音声の話者埋め込みをターゲットへ微分監督する自前機構 — を提案する。CIPT により held-out 男性→女性の SECS を 0.5 → 0.63 まです押し上げ、聴感でも本人性が段階的に向上した。外部 VC 手法の移植には依らない(Frontier)。

1. 基盤モデル m3b と推論経路

目標は ASMR・官能バ美酒向けリアルタイム VC(推論 Rust/Candle・学習 PyTorch・MIT・E2E 50ms 未満)。m3b は source の content(何を)× target の identity(誰の声)× F0(高さ)を分離する source-filter 型 VC。推論経路を図 1 に示す。




図 1. 推論。ContentVec(話者分離 content)+srcshift F0+energy を、ContentScrub(GRL)後に NSF-HiFiGAN 生成器へ。話者は参照 mel→TimbreEncoder(ECAPA 蒸留)の埋込 s を AdaIN 注入。補助モデルは学習のみ、推論は自前経路。

主要諸元: 44.1kHz / hop512 / 86Hz フレーム / mel128。content = ContentVec(768, HuBERT 系)。話者 s (192, ECAPA-TDNN へ cosine 蒸留)。F0 = source 実コントゥアを target 中央値へ線形移動(srcshift)。学習型 F0 は warble で不採用。

2. 問題: 本人らしさの天井

決定的な切り分け: 女性発話の自己再構成は人物同一性 二重丸(SECS $\approx$ 0.9)だが、男性→女性変換は SECS $\approx$ 0.5 で頭打ちで、参照埋込を生 ECAPA に差し替えても超えない。

診断: decoder は本来 identity を出せる(recon が証拠)。天井の原因は 男性 content が source 同一性を漏らし、decoder がそれを忠実にレンダリングすること。かつ m3b の学習は id loss を 埋め込み (TimbreEncoder $\approx$ ECAPA)にのみ課し、mel/GAN は全て 自己再構成。→ 「他人(男性) content に target 同一性を上書きする」出力を一度も監督していない。これが天井の根。

反復自己精製(出力を再変換)で SECS が上がる事実は原理を裏付けたが、多重ループは再 vocode で構音を破壊するため不可。→ 壊さず 1 パスで出力側を監督する機構が必要。

3. CIPT: 出力側同一性の微分監督

原理: cross-speaker 変換(content=話者 X, target=話者 Z)を生成し、生成音声の ECAPA 埋込を e_Z へ微分逆伝播する。ECAPA は loss のみ(推論非依存, 合法)。

予備実験 A1(失敗・重要な負): decoder を凍結し content 精製器のみ学習 → held-out SECS は +0.03 の微小ピーク後に減衰。凍結 decoder + content 微調整では identity を頑健に押せない → decoder 自体に容量を与える必要。

本手法 A2: 図 2 の二ストリームで decoder(+TimbreEncoder+ContentScrub)を fine-tune。




図 2. CIPT 学習。共有 Generator に 2 ストリーム。self-recon(女性, GT あり): mel+MR-STFT+GAN+id で品質・構音を担保。cross(男性→女性, GT なし): 生成 $\hat{y}_x$ の ECAPA を e_{tgt} へ (L_{idout})、ContentVec を男性 content に一致 ($L_{構音}$)、さらに $\hat{y}_x$ を Discriminator の fake に入れ実音声多様体へ拘束。

設計の要点(いずれも成立に必須): (1) decoder fine-tune(凍結不可)。 (2) male→female 実分布で cross 学習(女性 cross のみでは汎化不足)。 (3) cross 出力を GAN の fake に — ECAPA を騙すだけのノイズ化を実音声多様体で抑止。 (4) ContentVec 一致で構音(何を喋るか)を固定。 (5) 女性 self-recon で品質担保。
cross 損失: $L_{cross} = 3\{-\}5 \cdot L_{idout} + 6 \cdot L_{構音} + 1\{-\}2 \cdot L_{xGAN}$ 。 self は m3b と同一(45 mel + 2 mrstft + 3 id + GAN + FM)。

4. 結果: 天井の突破

held-out 男性→女性 2 ペアの SECS(ECAPA cosine, 高いほど本人)。source→target は元来 0.0~0.1。

段階	pair0	pair1	flat 2-8k ↓	聴感
source→target (元)	+0.10	+0.00	—	別人
m3b (天井)	+0.446	+0.508	0.51/0.53	女性だが本人不足
CIPT w3 (初成功)	+0.478	+0.570	0.47/0.67	本人ばい
CIPT w5 (押し込み)	+0.508	+0.632	0.56/0.74	本人・やや荒い
target (参照上限)	—	—	0.45/0.59	—

pair1 で +0.508 → +0.632(m3b 比 +0.124)と 0.5 天井を明確に突破。学習は 単調上昇・無劣化で完走し、cross-GAN が ECAPA 敵対的騙し(ノイズ化)を防いだ。聴感でも m3b→w3→w5 と本人性が段階的に向上(耳判定で確認)。

知見: SECS は知覚を過小評価する指標(kNN-VC は高 SECS でも音質不良で失格した前例)。従って最終判定は常に 耳。CIPT の SECS 上昇は聴感一致で裏付けられた。

5. 音質の詰め (Phase B, 進行中)

w5 は本人性で合格だが「透明感・ツヤ不足／やや荒い」との kansei 指摘。スペクトル診断で原因を客観化した(表: spectral flatness 2-8k = 倍音間ノイズ=荒さ指標)。

target 0.45-0.59 / w5 0.56-0.74(全手法中最悪) / w3 0.47-0.67 / m3b 0.51-0.53。 → 強い identity 押し込み(w_idout=5)がスペクトルにノイズを乗せたのが「荒さ」の正体。高域エネルギー自体は過剰だがノイズで、透明感/ツヤを masking している。

対策(anneal): identity は既に重みに焼き付いた(banked)ため、w5 から w_idout を下げ(→2)・cross-GAN を強め(→2)で再学習。GAN が実女性音声の clean な多様体へ引き戻し、flatness を target 水準へ下げる。荒さ除去で透明感・ツヤが顕在化する狙い(耳で確定予定)。

6. リアルタイム/ストリーミング推論 (課題)

RVC は ContentVec が双方向 self-attention のため、音声をチャンクに区切って buffer + crossfade する。これがチャンク遅延(100-300ms)の主因。本アーキはフレーム同期のストリーミングが可能な設計だが、現行 checkpoint は同じく双方向 ContentVec に依存するためそのままでは非ストリーミング。以下に道筋を示す。




図 3. ストリーミング推論経路。話者 s は target 参照から 1 回計算しキャッシュ(灰=オフライン)。以降は入力フレーム毎に因果処理。因果性: ✓因果 / △有界先読み / ✕要 causal 化。

段	因果性	備考
ContentVec (content)	✕ 双方向	唯一の本質的ボトルネック。未来フレームを見る
TimbreEncoder (s)	✓ オフライン	target 参照から 1 回・キャッシュ。毎フレーム不要
ContentScrub	✓ 完全因果	kernel=1 pointwise conv
Energy	✓ 完全因果	フレーム RMS
F0 (srcshift)	△ 小先読み	因果 pitch tracker / neural F0 で 0-20ms
NSF-HiFiGAN 生成器	△ 有界先読み	受容野ぶん(数フレーム)。causal conv 化でゼロ可
CIPT (identity)	✓ 無影響	学習手法。推論経路を変えない

障壁と解: ボトルネックは ContentVec の双方向性(RVC と同根)。ただし本研究には「純 causal で双方向と同質・lookahead 不要」の負の結果(生成経路で複数検証)があり、未来を見なくても品質は落ちない。よって解は ContentVec を causal content encoder に蒸留(オンラインで content 相当を因果生成) — decoder はそのまま流用可。話者 s ・F0 が content から分離・前計算/因果な点が RVC と異なり、チャンク不要のフレーム同期を可能にする。


レイテンシ試算: frame hop = 512/44100 = 11.6ms。causal content enc.(0) + 低先読み decoder + causal F0 → アルゴリズム遅延 $\approx$ 1-3 フレーム(12-35ms) + 演算時間。目標 E2E 50ms 未滿は射程内で、RVC のチャンク遅延を大きく下回れる。演算: NSF-HiFiGAN 14M は GPU/XPU で余裕 RT、CPU(Rust/Candle)でも最適化で RT 可。

残工程: (1) causal content encoder の蒸留、(2) 生成器の causal conv 化(or 有界先読み許容)、(3) causal F0。最大の不確実性(causal で品質劣化?)は既に否定済み。

7. 生成器詳細(参考)

(a) 生成器スタック

(b) UpBlock



8. 知見と今後

検証して不採用にした経路(負の知見): 学習 F0(warble「婆さん」) / 構音 clone s_{art} (自己再構成では勾配出ず, 2回) / cross-style parallel(DTW artifact) / few-shot(男性 content 漏れ不変) / kNN-VC(音質不良・SECS 劣位, 外部手法) / CIPT-A1(凍結 decoder では押せず)。

成立した本線: CIPT-A2 — 出力側同一性の微分監督 + decoder fine-tune + cross-GAN + ContentVec 構音固定。

今後: (Phase B) 音質 anneal で透明感/ツヤ。(Phase C) 萌え/官能の kansei 軸 — 出力側勾配が通る今、self-recon では動かなかった構音/スタイル軸を出力監督で再挑戦(human-in-the-loop)。並行してリアルタイム/streaming(E2E 50ms 未満)と Rust/Candle パリティ。