

LightVC — m3b 基盤 VC

男性(中性)→ターゲット女性 ゼロショット音声変換 / アーキテクチャと学習

2026-07-08 時点スナップショット

1. 概要と目標

ASMR・官能バ美肉向けのリアルタイム音声変換。推論は全て Rust (Candle)、学習は PyTorch、MIT ライセンス、E2E 50ms 未満、XPU 対応を目標とする。m3b は「エフェクト音声」から脱し「ターゲット女性が喋っている」自然な声を成立させた 基盤 (foundation) モデルであり、以降の本人性・萌え表現はこの上に積む。

基本方針: source の content(何を) × target の identity(誰の声) × F0(高さ) を分離し、推論時 GUI でリアルタイム補正可能に保つ。補助モデル(ContentVec / ECAPA)は loss・表現供給に使うが、最終推論の本体アルゴリズムは自前で構成する(Frontier 研究)。

2. 信号諸元

サンプル率	44,100 Hz	STFT / 窓	N_FFT 2048 / 2048
ホップ長	512 (11.6ms)	フレーム率	86.13 Hz
メル帯域	128	F0/energy	86Hz フレーム

3. 推論パイプライン (システム全体)




図 1. 推論データフロー。橙=入出力、青=学習モジュール(推論で使用)、緑=生成器、破線=学習時のみ。source から content/ F0/energy、target 参照から話者埋込 s を得て生成。

4. モジュール詳細

4.1 NSF-HiFiGAN デコーダ (nsf_hn.py)

Source-filter 型ニューラルボコーダ。HiFiGAN 生成器に NSF(Neural Source-Filter) 励振を統合。図 2 に全体スタックと UpBlock 内部を示す。




図 2. 生成器。(a) cond→conv_pre→6 段 UpBlock(ch を半減しつつ長さを×512)→conv_post→波形。F0 由来の source を各段へ励振注入、s を AdaIN 注入。(b) 各 UpBlock の内部。

4.2 TimbreEncoder (話者埋め込み, ECAPA 蒸留)

参照 mel(128) → 4 層 Conv(256ch, stride で 1/4) → 統計プーリング(時間方向 mean+std) → 線形 → 192 次元 s 。学習中に ECAPA-TDNN 埋め込み(speechbrain spkrec-ecapa-voxceleb, 192 次元)へ cosine 蒸留し、強いゼロショット話者性を獲得。推論時は本エンコーダのみ使用(SV 非依存、Rust 移植可)。

4.3 ContentScrub (話者漏れ抑制, GRL)

Content(768) → Conv 768→512→768 の残差(最終層零初期化)。勾配反転層(GRL) 経由で話者分類器(回帰)を敵対学習し、content から残留話者を除去 → 話者性を埋め込み側に集約。

4.4 F0: srcshift

学習型 F0 予測器は warble(揺れ)で「婆さん声」化するため不採用。代わりに source の実 F0 コントウア(自然な微変動)を保持しつつ、レジスタ(中央値)のみ target 参照へ線形移動: $F0' = F0_{src} \cdot (\text{med}_{tgt} / \text{med}_{src})$ 。source の抑揚を残しつつ女性音域へ。

5. 学習プロセス

学習時グラフ(推論と同一の生成器 + 学習時のみの弁別器・GRL 敵対器・ECAPA 教師)を次の横向きページの図 3 に示す。




図 3. 学習グラフ。赤=損失。生成器(緑)は図 1・2 と同一。ECAPA 教師埋込(事前計算,破線)へ TimbreEncoder を cosine 蒸留、ContentScrub は GRL で話者除去(cemb_pred 敵対器)。実波形 y /生成 $\hat{y}$ を Discriminator2 で GAN+FM。弁別器・GRL 敵対器・ECAPA 教師は全て推論では破棄。

5.1 Warm-start チェーン

m1_v2 NSF-HiFiGAN ボコーダ (content→波形) を単体で試聴可能水準まで学習
→ m2_vc6 TimbreEncoder(AdaIN 音色) + ContentScrub + 多解像度弁別器を追加
→ m3 TimbreEncoder を ECAPA へ cosine 蒸留、content-scrub(GRL)、F0 は srcshift へ
→ m3b content 摂動(content_pert) 学習でクロスジェンダーの content 汎化を強化

5.2 損失 (生成器) と学習設定

Mel L1 ×45 mel L1(再構成中核)
MR-STFT ×2 複数解像度スペクトル
Identity ×3 $1 - \cos(s, e)$ 蒸留
Content-adv ×0.1 GRL 話者除去
GAN adv ×1 LSGAN
Feature match ×2 弁別器中間特徴

データ 女性 2,760 発話
セグメント 32 フレーム
最適化 AdamW lr 2e-4
バッチ 16
GRL α 10k step で 0.5
摂動 WORLD formant/pitch

6. 推論ネットワーク詳細 (層仕様)

B =バッチ, T =フレーム数(86Hz)。出力は $T \cdot 512$ サンプル。

層	種別	ch in→out	k / stride	出力 [ch, len]
入力 cond / F0 / s	—	—	—	[770,T] / [T] / [192]
Source module (NSF 励振)				
F0 upsample	linear interp ×512	—	—	[1, 512T]
SineGen	正弦調波(9 本)+noise	—	—	[512T, 9]
l_linear + tanh	Linear	9→1	—	[1, 512T] = source
本体 (HiFiGAN 生成器 + AdaIN)				
conv_pre	Conv1d	770→512	7 / 1	[512, T]
up0 (+noise/AdaIN/MRF×3)	ConvTranspose1d	512→256	16 / 8	[256, 8T]
up1 (+noise/AdaIN/MRF)	ConvTranspose1d	256→128	8 / 4	[128, 32T]
up2 (+noise/AdaIN/MRF)	ConvTranspose1d	128→64	4 / 2	[64, 64T]
up3 (+noise/AdaIN/MRF)	ConvTranspose1d	64→32	4 / 2	[32, 128T]
up4 (+noise/AdaIN/MRF)	ConvTranspose1d	32→16	4 / 2	[16, 256T]
up5 (+noise/AdaIN/MRF)	ConvTranspose1d	16→8	4 / 2	[8, 512T]
conv_post + tanh	Conv1d	8→1	7 / 1	[1, 512T] = 波形

AdaIN film: 各段 i で $\text{Linear}(192 \rightarrow 2 \cdot \text{ch}_i)$ が (γ_i, β_i) を出力し $x \leftarrow \text{IN}(x)(1 + \gamma_i) + \beta_i$ (零初期化)。生成器 約 14M params。推論依存=生成器+TimbreEncoder+ContentScrub+ContentVec のみ。

6.1 Discriminator2 (学習のみ, 3 系統 11 弁別器)

系統	数	構造
MPD (周期)	5	period 2,3,5,7,11。Conv2d 1→32→128→512→1024→1024→1、(5,1)stride(3,1)
MSD (スケール)	3	生/×2/×4 pool。Conv1d 1→128→...→1024→1、grouped、kernel 41
MRD (スペクトル)	3	STFT(512/1024/2048)、Conv2d on log-mag、32ch×4→1

生成器総損失: $L_G = 45L_{\text{mel}} + 2L_{\text{mrstft}} + 3L_{\text{id}} + 0.1L_{\text{cadv}} + L_{\text{gadv}} + 2L_{\text{fm}}$ 。弁別器: $L_D = \sum_k (D_k(y) - 1)^2 + D_k(\hat{y})^2$ (LSGAN)。

7. 到達状況と知見

成立: ・デコーダ無罪(女性自己再構成=人物同一性 二重丸、mel-L1 0.5 は聴感無関係)。・srcshift で F0 自然化。・ECAPA 蒸留+content 摂動で SECS を source 0.02~0.09 → 0.50~0.58(「コア声質は似てきた」)。

課題: 出力 SECS が生 ECAPA(天井)でも 0.5~0.58 で頭打ち = 男性 content が source 同一性を漏らし出力を引き戻す(女性 content 自己再構成が二重丸なのが傍証)。単一 ECAPA 埋込+AdaIN では固有の細部を押し切れない。

不採用(負の知見): 学習 F0(warble 「婆さん」) / 構音 clone s_art(自己再構成では勾配出ず無効果, 2 回) / cross-style parallel(DTW artifact+学習推論ミスマッチ) / few-shot(男性 content 漏れ不変) / kNN-VC(音質不良・SECS 劣位, 外部手法ゆえ Frontier 方針で不採用)。